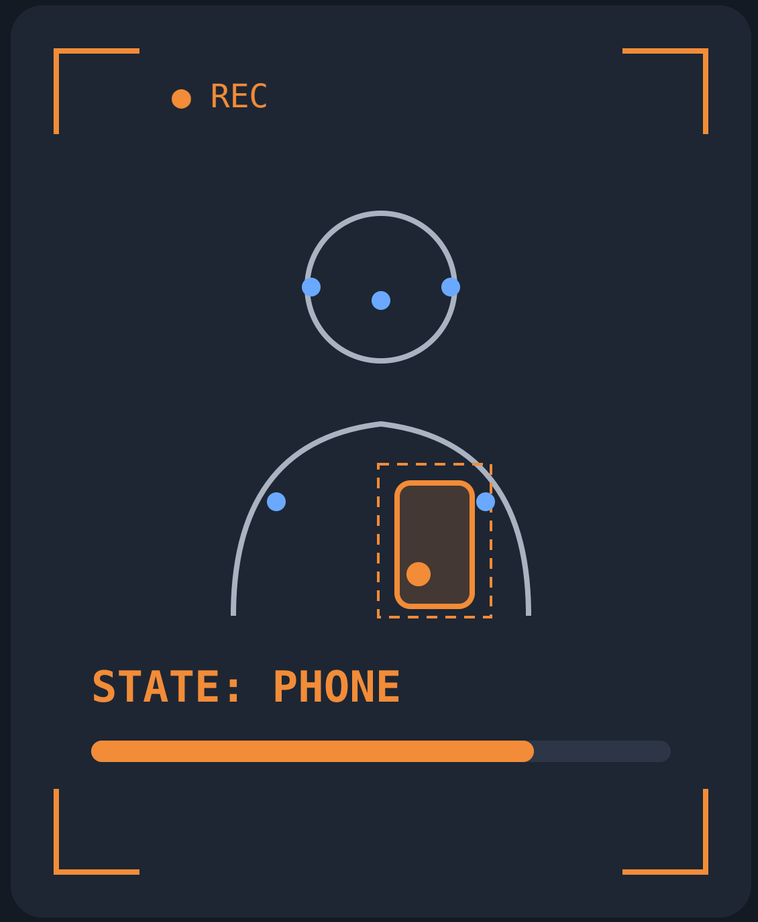
FINAL PROJECT · VISION-LLM MULTIMODAL SYSTEM

Focus Guard

“왜 집중 안 해?” 묻고, 변명까지 듣는 AI 공부 감독관



[이름 · 학번] · 가천대학교 Physical AI · 2026.11.08

01 · 문제 정의

혼자 공부하면, 딴짓을 지적해 줄 사람이 없다

기존 방법

타이머 · 앱 차단

- 내가 실제로 무엇을 하는지 모른다
- 알림은 일방적이라 쉽게 무시된다
- 왜 집중이 깨졌는지 남는 기록이 없다

Focus Guard

보고, 묻고, 듣는다

- 카메라로 휴대폰 · 자세 · 시선을 인식
- “왜 집중 안 해?” 음성으로 직접 질문
- 내 변명을 듣고 타당한지 AI가 판단

02 · 시스템 개요

AI 감독관이 하는 일은 세 가지

STEP 1

본다

YOLO와 MediaPipe Pose로 휴대폰, 고개 방향, 자세를 매 프레임 인식

STEP 2

묻는다

이탈이 3초 이어지면 Gemma가 장면을 보고 “왜 집중 안 해?”라고 음성으로 질문

STEP 3

듣고 판단한다

Whisper로 변명을 듣고, Gemma가 타당한지 판단해 음성으로 답변

전체 파이프라인

① VISION — 매 프레임 (메인 루프)

카메라
Jetson CSI · GStreamer

▶

YOLO11n INT8
휴대폰 · 책 · 노트북 탐지

▶

MediaPipe Pose
손목 · 코 · 귀 · 어깨 랜드마크

▶

규칙 기반 판단
5가지 상태 + 지속 시간

▶

이벤트 발생
이탈 3초 지속 → ②로 전달

② LLM · 음성 — 이벤트 발생 시 (워커 스레드)

상태 JSON
→ 자연어 Context 변환

▶

Gemma 4 E2B
Context + 프레임 이미지 (mmproj)

▶

Piper TTS
“왜 집중 안 해?”

▶

Whisper STT
사용자의 변명 인식

▶

Gemma 판단
타당한가? → TTS로 답변

04 · 수업 내용 통합

섹션 2~6에서 배운 것을 하나로 연결했다

섹션	배운 것	프로젝트에서 사용
2 · Computer Vision	카메라 피드 · MediaPipe 신체 인식	CSI 카메라 + Pose 랜드마크로 자세 판단
4 · Object Detection	YOLO11n · TensorRT INT8 양자화	휴대폰 · 책 · 노트북 실시간 탐지
5 · LLM & Gemma	Gemma 4 · 프롬프트 설계	꾸짖기 · 변명 판단 · 리포트 프롬프트 4종
6-A · Vision-to-Text	YOLO → JSON → 자연어 Context	상태 JSON 저장 → 자연어로 Gemma에 전달
6-A · 파이프라인 분리	Vision과 LLM 실행 분리	카메라 루프와 LLM · 음성 스레드 분리
6-B · 멀티모달	이미지 + 텍스트 동시 입력	이탈 순간의 카메라 프레임을 함께 전달
6-C · STT / TTS	whisper.cpp · Piper	변명 듣기 · 음성으로 꾸짖기

05 · 상태 판단

다섯 가지 상태를 규칙으로 판단한다

FOCUS

집중

이탈 조건 없음. 책을 들고 고개를 숙이면 독서로 보고 집중 처리

PHONE

휴대폰 사용

휴대폰이 손목 근처에 있거나 사람 영역과 겹침

LOOKING_AWAY

딴 곳 보기

코가 귀 중심에서 크게 벗어나거나 한쪽 귀만 보임

HEAD_DOWN

졸음 의심

공부 물건 없이 코가 어깨선 가까이 내려옴

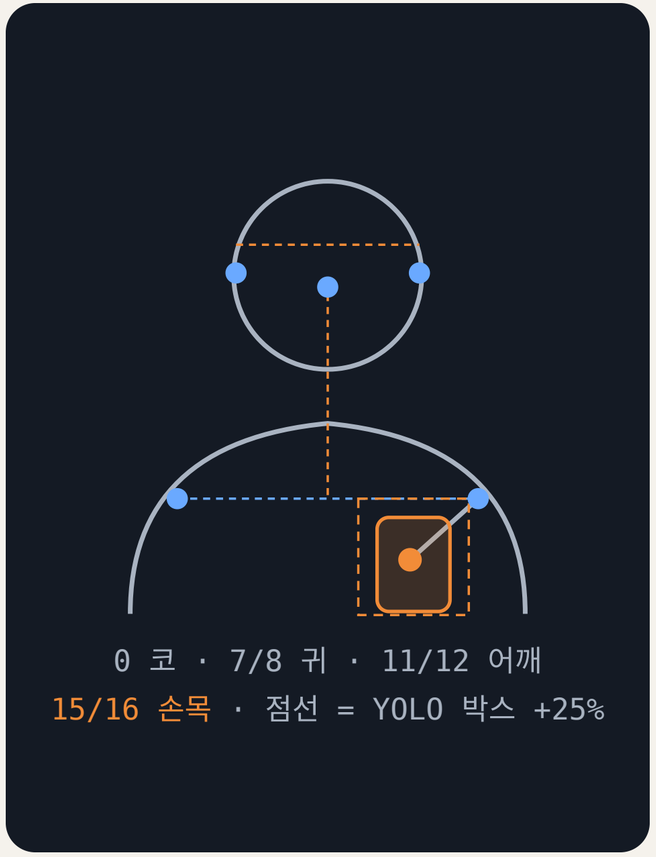
ABSENT

자리 비움

사람도, 자세 랜드마크도 탐지되지 않음

판단 우선순위 **자리 비움 → 휴대폰 → 딴 곳 보기 → 졸음 → 집중**

MediaPipe 랜드마크로 계산하는 세 가지 규칙



① 손에 든 물체

```
손목·검지(15,16,19,20) ∈ bbox × 1.25
```

YOLO 박스를 25% 넓혀서 손이 들어오면 HELD로 판단

② 고개 회전

```
|코x − 귀중심x| ÷ 귀 간격 > 0.35
```

또는 한쪽 귀만 보이면 고개를 돌린 것으로 판단

③ 고개 숙임

```
(어깨중심y − 코y) ÷ 어깨 너비 < 0.15
```

단, 책을 들고 있으면 독서로 보고 집중 처리

07 · 이벤트 트리거

순간이 아니라 ‘지속’될 때만 경고한다

3초

이탈 지속 시간

휴대폰 · 딴 곳 · 졸음 상태가 3초 이어지면 경고. 화면 게이지로 표시

6초

자리 비움

잠깐 일어나는 건 봐주도록 기준을 더 길게

15초

경고 쿨다운

AI가 말하거나 듣는 중에는 새 경고를 만들지 않음

→ 잠깐 고개 돌린 것 같은 오탐과, 연속 잔소리를 함께 줄인다

08 · Vision → Text → Gemma

장면을 글로 바꾸고, 이미지와 함께 묻는다

Context — 상태 JSON → 자연어

현재 상태: 휴대폰 사용
손에 든 물체: cell phone
주변 물체: 없음
이 상태가 지속된 시간: 4초
공부 시작 후 경과 시간: 12.5분
지금까지 집중이 끊긴 횟수: 2번
전체 집중률: 81%

System Prompt — 꾸짖기

Instruction:
AI 공부 감독관으로서 집중하지 않는 이유를
지적하고, 왜 집중하지 않느냐고 물어보시오.

Constraint:
확인되지 않는 내용은 추측하지 마시오.
“왜”로 시작하는 질문을 반드시 포함하시오.

Output Format:
한국어 구어체 두 문장 이내.

+ 이탈 순간의 카메라 프레임 이미지를 함께 입력 (Gemma4ChatHandler · mmproj) · 숫자는 예시

09 · 변명 듣기

같은 질문, 변명에 따라 다른 대답

HEAD_DOWN · 타당한 이유

AI 감독관
고개가 계속 숙여져 있네요. 왜 졸고 있어요?

나
아 머리 아파서 잠깐 쉬는 거야

AI 감독관
그럼 5분만 쉬고, 물 한 잔 마신 다음 다시 시작해요.

PHONE · 핑계

AI 감독관
휴대폰 내려놓으세요. 왜 공부 안 하고 휴대폰 보고 있어요?

나
그냥 잠깐 인스타 봤어

AI 감독관
잠깐이 벌써 두 번째예요. 폰은 뒤집어 두고 다시 집중합시다.

* 예시 시나리오입니다. 실제 문장은 Gemma가 상황 정보와 이미지를 보고 매번 새로 생성합니다.

10 · 실시간 구조

AI가 생각하는 동안에도 화면은 멈추지 않는다

메인 루프 · 매 프레임

1. 카메라 프레임 읽기
2. YOLO 물체 탐지 + Pose 랜드마크 추정
3. 상태 판단 · 지속 시간 타이머
4. 화면 오버레이 (상태 · 게이지 · 집중률)

작업 큐

워커 스레드 · 이벤트 처리

1. Gemma 꾸짖기 → Piper 음성 출력
2. Whisper로 변명 녹음 · 인식
3. Gemma 판단 → 음성 답변
4. v 키: 음성 질문 · r 키: 공부 리포트

노트북에서 개발 → Jetson에서 실행 구성요소가 없으면 자동 대체: .engine → .pt · 멀티모달 → 텍스트 · STT → 키보드 · TTS → 콘솔

11 · 시연

직접 보여드리겠습니다

1

책을 들고 고개 숙이기

→ 집중 유지

2

휴대폰 들기

→ 3초 게이지 → 음성 경고

3

변명하기

→ Gemma가 판단해 대답

4

r 키

→ 오늘의 공부 리포트

한계와 다음 단계

한계

- 카메라가 정면 · 상반신을 봐야 정확함
- COCO에 펜 · 필기 클래스가 없어 필기 여부는 판단하지 못함
- 임계값이 사람 · 자세마다 달라 튜닝이 필요
- 엣지 기기에서 Gemma 이미지 추론은 응답 지연이 있음

확장

- 시작할 때 정자세를 측정하는 개인별 캘리브레이션
- 영유아 수면 안전 모니터: 얼굴 랜드마크가 사라지면 이불 덮임 경고 (같은 파이프라인)
- 공부 기록을 쌓아 주간 리포트 · 대시보드 제공

Q & A

감사합니다

Focus Guard — YOLO · MediaPipe · Gemma · Whisper · Piper on Jetson

[이름 · 학번]